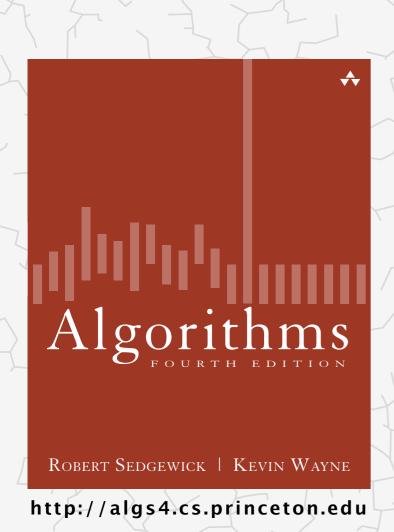
Algorithms



3.4 TABELAS HASH

- Funções de hash
- Encadeamento separado
- Exploração linear
- **▶** Contexto

Sumário: implementações de dicionário

Implementação		Garantia			Caso médio	Operações ordenadas	Interface	
impiementação	search	insert	delete	search hit	insert	delete	?	Principal
Busca sequencial (array aleatório)	N	N	N	½ N	N	½ N		equals()
Busca binária (array ordenado)	lg N	N	N	lg N	½ N	½ N	~	compareTo()
ABP	N	N	N	1.39 lg <i>N</i>	1.39 lg <i>N</i>	\sqrt{N}	•	compareTo()
ABP balanceada (ex: rubro-negra)	2 lg <i>N</i>	2 lg <i>N</i>	2 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	•	compareTo()

- P. Podemos fazer melhor?
- R. Sim, mas com uma forma diferente de acesso aos dados.

Hashing: plano básico

Armazenar itens em uma tabela indexada por chave (índice é uma função sobre a chave).

Função de hash: Método para calcular um índice no array a partir de uma chave.

hash("it") = 3

Questões:

- Como calcular a função de hash?
- Teste de igualdade: como testar se duas chaves são iguais?
- O que fazer em caso de colisões chaves que "caem" na mesma posição do array.

Clássico dilema de espaço x tempo:

- Sem limitação de espaço: função de hash é a própria chave!
- Sem limitação de tempo: solução trivial de colisões com busca sequencial
- Limitações de espaço e tempo: hashing (o mundo real).

0

?? 3

hash("times") = 3

4

"it"

Algorithms

ROBERT SEDGEWICK | KEVIN WAYNE

http://algs4.cs.princeton.edu

3.4 TABELAS HASH

- Funções de hash
- Encadeamento separado
- Busca linear
- Contexto

Calculando a função de hash

Objetivo ideal: Espalhar as chaves de forma uniforme.

- Eficientemente computável
- Cada índice igualmente provável para cada chave.

Problema amplamente pesquisado, ainda problemático para aplicações práticas

Ex 1. Números de telefone.

- Ruim: primeiros três dígitos.
- Melhor: últimos três dígitos.



Ex 2. Números de matrícula.

- Ruim: primeiros três dígitos. (ano e semestre de entrada de cada aluno)
- Melhor: últimos três dígitos.

Desafio prático: Exige abordagens diferentes para cada tipo de chave.

Convenções de hashCode em Java

Todas as classes Java herdam um método hashCode(), que retorna um número inteiro de 32 bits.

Implementação padrão: Endereço de memória de x.
Implementação legal (mas ruim): Sempre retornar, por ex., 17.
Implementações customizadas: Integer, Double, String, File, URL, Date, ...
Tipos criados pelo usuário: Usuários são responsáveis por criar hashCode

Implementando hashCode: inteiros, booleans e doubles

Implementações da biblioteca Java

```
public final class Integer
{
   private final int value;
   ...

public int hashCode()
   { return value; }
}
```

```
public final class Boolean
{
    private final boolean value;
    ...

public int hashCode()
    {
        if (value) return 1231;
        else return 1237;
    }
}
```

```
public final class Double
{
    private final double value;
    ...

public int hashCode()
    {
       long bits = doubleToLongBits(value);
       return (int) (bits ^ (bits >>> 32));
    }
}
```

converte para representação IEEE 64-bit; xor 32 bits mais significativos com os 32 menos significativos

Cuidado: -0.0 e +0.0 têm hashCode diferente!

Implementando hashCode: strings

Implementação da biblioteca Java

```
public final class String
{
    private final char[] s;
    ...

public int hashCode()
    {
        int hash = 0;
        for (int i = 0; i < length(); i++)
            hash = s[i] + (31 * hash);
        return hash;
        }
        Caractere na posição i
}</pre>
```

char	Unicode
'a'	97
'b'	98
'c'	99

- Método de Horner para string de tamanho L: L multiplicações/somas.
- Equivalente a $h = s[0] \cdot 31^{L-1} + ... + s[L-3] \cdot 31^2 + s[L-2] \cdot 31^1 + s[L-1] \cdot 31^0$.

```
Ex: String s = \text{"call"};

int code = s.hashCode(); \longrightarrow 3045982 = 99.31^3 + 97.31^2 + 108.31^1 + 108.31^0

= 108 + 31 \cdot (108 + 31 \cdot (97 + 31 \cdot (99)))

(Método de Horner)
```

Hashing modular

```
Código de hash: Um int entre -231 e 231 - 1.
```

Função de hash: Um int entre 0 e M - 1 (usado com índice num array).

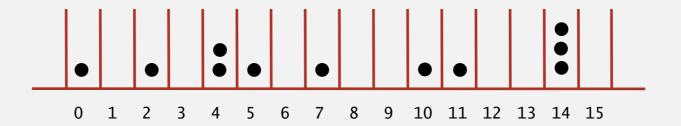
Tipicamente um primo ou potência de 2

```
X
 private int hash(Key key)
     return key.hashCode() % M; }
bug
                                                                 x.hashCode()
 private int hash(Key key)
     return Math.abs(key.hashCode()) % M; }
Bug 1-em-um-bilhão
                                                                    hash(x)
                     hashCode() de "polygenelubricants" é -231
 private int hash(Key key)
     return (key.hashCode() & 0x7fffffff) % M; }
Correto (ignora o bit de sinal)
```

Condição de hashing uniforme

Hashing uniforme: A probabilidade de cada chave gerar um inteiro entre 0 e M-1 é sempre a mesma para todas as chaves.

Cestos e bolas: Atire bolas aleatoriamente em M cestos.



Problema do aniversário: Espere duas bolas no mesmo cesto depois de $\sim \sqrt{\pi M/2}$ lançamentos.



Algorithms

ROBERT SEDGEWICK | KEVIN WAYNE

http://algs4.cs.princeton.edu

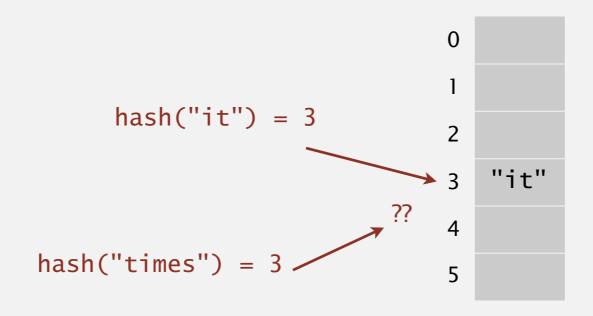
3.4 TABELAS HASH

- Funções de hash
- Encadeamento separado
- Exploração linear
- Contexto

Colisões

Colisão: Duas chaves que geram hash para o mesmo índice.

- Problema do aniversário ⇒ impossível evitar colisões a não ser que tenhamos uma quantidade enorme de memória (quadrática).
- Colisões estão igualmente distribuidas.

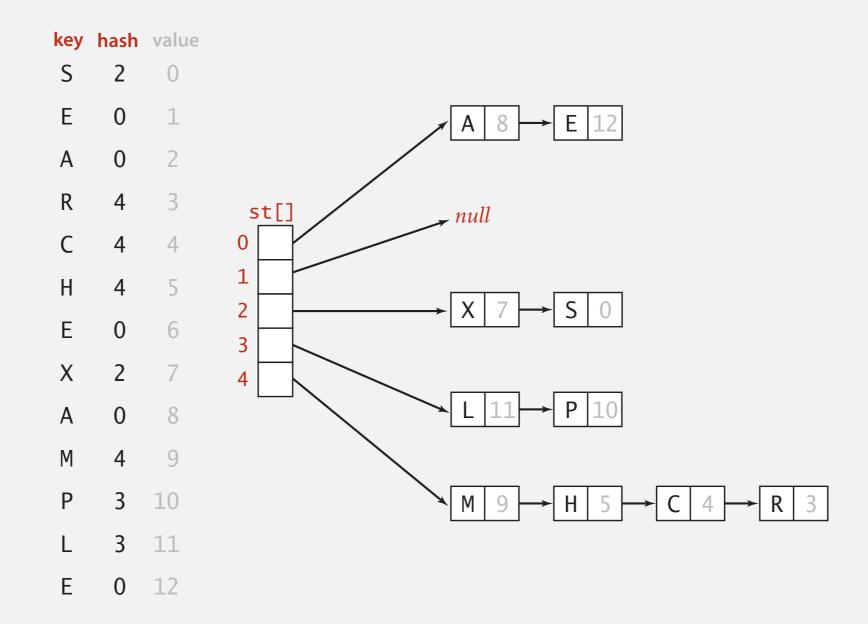


Desafio: Como lidar eficientemente com colisões.

Encadeamento separado

Usar um array de M < N listas encadeadas. [H. P. Luhn, IBM 1953]

- Hash: mapeia chave para inteiro i entre 0 e M-1.
- Inserção: inserir no início da lista na posição i (se já não estiver lá).
- Busca: precisa procurar apenas na lista *i*.



Encadeamento separado: implementação Java

```
public class SeparateChainingHashST<Key, Value>
  private int M = 97;
                        // number of chains
  private Node[] st = new Node[M]; // array of chains
  private static class Node
     private Object key; — Java não permite criação de array genérico
      private Object val; ← (declara-se key e value do tipo Object)
      private Node next;
  private int hash(Key key)
   { return (key.hashCode() & 0x7fffffff) % M; }
  public Value get(Key key) {
     int i = hash(key);
      for (Node x = st[i]; x != null; x = x.next)
        if (key.equals(x.key)) return (Value) x.val;
      return null;
```

Código para dobrar e reduzir à metade o tamanho do array foi omitido

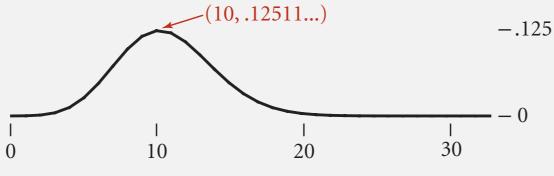
Encadeamento separado: implementação Java

```
public class SeparateChainingHashST<Key, Value>
  private int M = 97;
                       // number of chains
  private Node[] st = new Node[M]; // array of chains
  private static class Node
     private Object key;
     private Object val;
     private Node next;
  private int hash(Key key)
  { return (key.hashCode() & 0x7fffffff) % M; }
  public void put(Key key, Value val) {
     int i = hash(key);
     for (Node x = st[i]; x != null; x = x.next)
        if (key.equals(x.key)) { x.val = val; return; }
     st[i] = new Node(key, val, st[i]);
```

Análise do encadeamento separado

Hipótese: Considerando hashing uniforme, a probabilidade que a quantidade de chaves em uma lista esteja dentro de um fator constante de N/M é extremamente próxima de 1.

Provando: Distribuição do tamanho de uma lista obedece uma distribuição binomial.



Binomial distribution $(N = 10^4, M = 10^3, \alpha = 10)$

equals() e hashCode()

Resultado: Número de acessos para busca/inserção é proporcional a N/M.

- M muito grande \Rightarrow muitas listas vazias.
- M muito pequeno \Rightarrow listas muito longas.
- Escolha usual: $M \sim N/4 \Rightarrow$ operações de tempo constante.

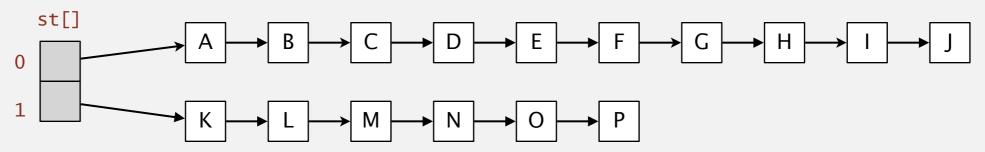
M vezes mais rápido que busca sequencial

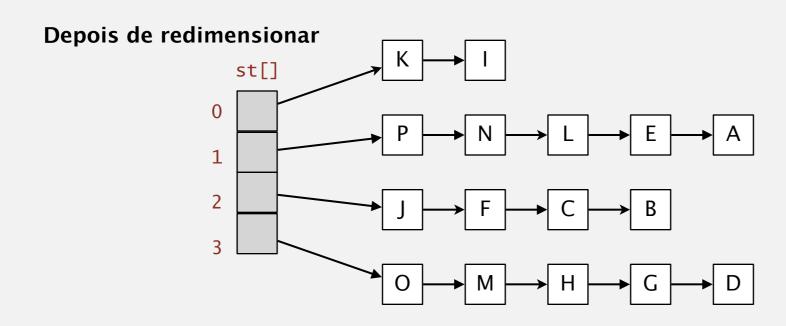
Redimensionamento no encadeamento separado

Objetivo: Manter o tamanho médio da lista = N/M = constante.

- Dobrar tamanho do array M quando $N/M \ge 8$.
- Reduzir pela metade o tamanho de M quando $N/M \le 2$.
- Precisa fazer hash em todas as chaves! ← x.hashCode() não muda, mas hash(x) pode mudar

Antes de redimensionar

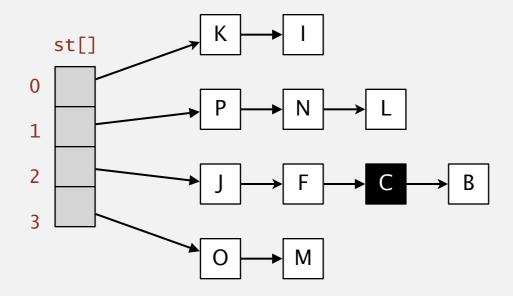




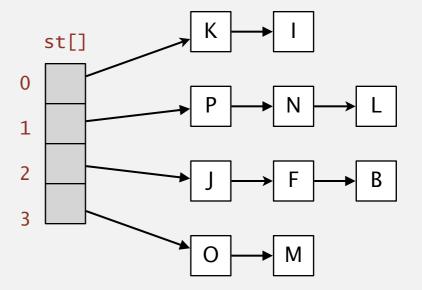
Remoção em encadeamento separado

- P: Como remover uma chave (e seu valor associado?)
- R: Fácil: precisa apenas considerar a lista contendo a chave.

Antes de remover C



Depois de remover C



Sumário: implementações de dicionário

Implomentação		Garantia			Caso médio		Operações ordenadas	Interface	
Implementação	search	insert	delete	search hit	insert	delete	?	principal	
Busca sequencial (array aleatório)	N	N	N	½ N	N	½ N		equals()	
Busca binária (array ordenado)	lg N	N	N	lg N	½ N	½ N	•	compareTo()	
ABP	N	N	N	1.39 lg <i>N</i>	1.39 lg <i>N</i>	\sqrt{N}	•	compareTo()	
ABP balanceada (ex: rubro-negra)	2 lg <i>N</i>	2 lg <i>N</i>	2 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	•	compareTo()	
Hashing por encadeamento separado	N	N	N	3-5 *	3-5 *	3-5 *		equals() hashCode()	

^{*} considerando hashing uniforme

Algorithms

ROBERT SEDGEWICK | KEVIN WAYNE

http://algs4.cs.princeton.edu

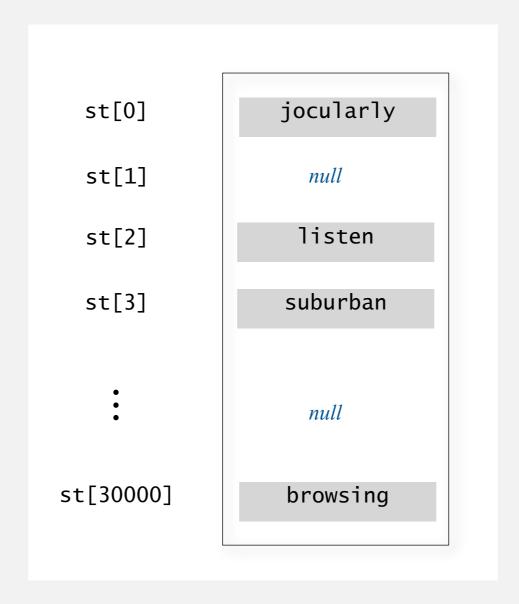
3.4 TABELAS HASH

- Funções de hash
- Encadeamento separado
- Exploração linear
- Contexto

Resolução de colisões: endereçamento aberto

Endereçamento aberto: [Amdahl-Boehme-Rocherster-Samuel, IBM 1953]

Quando uma nova chave colide, encontra um espaço livre e armazena ela nele.



Exploração linear (M = 30001, N = 15000)

Exploração linear: demonstração

Hash: Mapeia chave para inteiro *i* entre 0 e *M-1*.

Inserção: Armazena no índice i se estiver livre, senão tenta i+1, i+2, etc.

Tabela hash por exploração linear

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
st[]																

M = 16



Exploração linear: demonstração

Hash: Mapeia chave para inteiro *i* entre 0 e *M-1*.

Inserção: Armazena no índice i se estiver livre, senão tenta i+1, i+2, etc.

search K hash(K) = 5



Não encontra (retorna null)

Exploração linear: sumário

Hash: Mapeia chave para inteiro *i* entre 0 e *M-1*.

Inserção: Armazena no índice i se estiver livre, senão tenta i+1, i+2, etc.

Busca: Busca na posição i, se estiver ocupada mas não for a chave, tenta i+1, i+2, etc.

Nota: Tamanho do array *M* precisa ser maior que a quantidade *N* de pares chave-valor.



M = 16

Exploração linear: implementação Java

```
public class LinearProbingHashST<Key, Value>
  private int M = 30001;
  private Value[] vals = (Value[]) new Object[M];
  private Key[] keys = (Key[]) new Object[M];
                                      { /* como antes */ }
  private int hash(Key key)
  private void put(Key key, Value val) {/* próximo slide */ }
  public Value get(Key key)
     for (int i = hash(key); keys[i] != null; i = (i+1) % M)
        if (key.equals(keys[i]))
            return vals[i];
     return null;
```

Código para dobrar e reduzir à metade o tamanho do array foi omitido

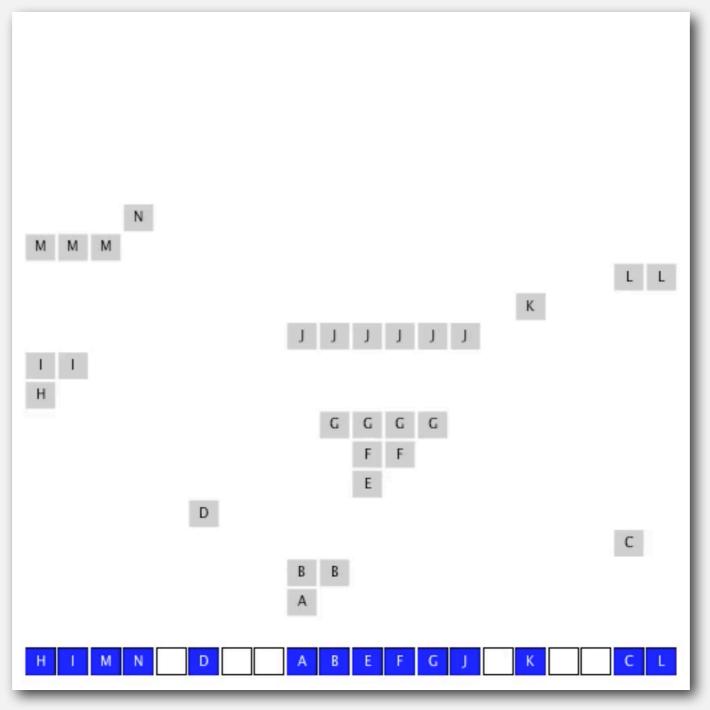
Exploração linear: implementação Java

```
public class LinearProbingHashST<Key, Value>
{
  private int M = 30001;
  private Value[] vals = (Value[]) new Object[M];
  private Key[] keys = (Key[]) new Object[M];
  private Value get(Key key) { /* slide anterior */ }
  public void put(Key key, Value val)
     int i;
     for (i = hash(key); keys[i] != null; i = (i+1) % M)
       if (keys[i].equals(key))
           break;
     keys[i] = key;
     vals[i] = val;
```

Clustering

Cluster: Um bloco contíguo de itens.

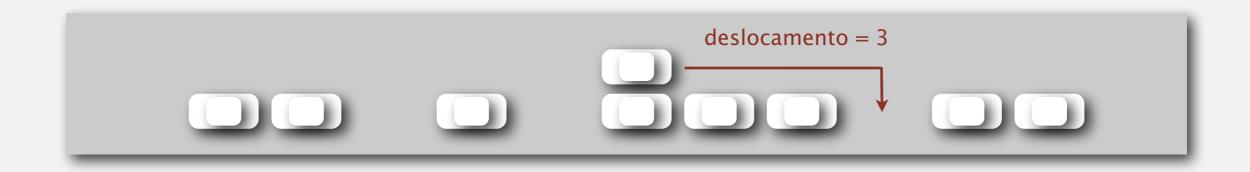
Observação: Novas chaves têm muitas chances de cairem no meio de clusters grandes.



Problema do estacionamento de Knuth

Modelo: Carros numa rua de mão única com M locais para estacionar. Cada um quer um local aleatório i: se estiver ocupado, tenta i+1, i+2, etc.

P: Qual é o deslocamento médio de um carro?



Metade cheio: Com M/2 carros, deslocamento médio é ~ 3/2.

Cheio: Com M carros, deslocamento é ~ $\sqrt{\pi} M/8$.

Análise da exploração linear

Proposição: Considerando hashing uniforme, a quantidade de consultas numa tabela hash de tamanho M que contém $N = \alpha M$ chaves é:

$$\sim \frac{1}{2} \left(1 + \frac{1}{1 - \alpha} \right) \qquad \sim \frac{1}{2} \left(1 + \frac{1}{(1 - \alpha)^2} \right)$$

Erro / inserção

 $\alpha \Rightarrow$ percentual de ocupação

Prova:

NOTES ON "OPEN" ADDRESSING.

1. Introduction and Definitions. Open addressing is a widely-used technique for keeping "symbol tables." The method was first used in 1954 by Samuel, Amdahl, and Boehme in an assembly program for the ThM 701. An extensive discussion of the method was given by Peterson in 1957 [1], and frequent references have been made to it ever since (e.g. Schay and Spruth [2], Iverson [3]). However, the timing characteristics have apparently never been exactly established, and indeed the author has heard reports of several reputable mathematicians who failed to find the solution after some trial. Therefore it is the purpose of this note to indicate one way by which the solution can be obtained.



Parâmetros:

- M muito grande \Rightarrow muitos espaços vazios no array.
- M muito pequeno ⇒ tempo de busca "explode".

Acerto

• Escolha típica: $\alpha = N/M \sim \frac{1}{2}$. # buscas para acerto: aprox. 3/2 # buscas para erro: aprox. 5/2

Redimensionamento em exploração linear

Objetivo: Manter o tamanho médio da busca $N/M \le \frac{1}{2}$.

- Dobrar tamanho do array M quando $N/M \ge \frac{1}{2}$.
- Reduzir à metade o tamanho do array M quando $N/M \leq \frac{1}{8}$.
- Necessário fazer hash de todas as chaves novamente.

Antes de redimensionar

	0	1	2	3	4	5	6	7
keys[]		E	S			R	Α	
vals[]		1	0			3	2	

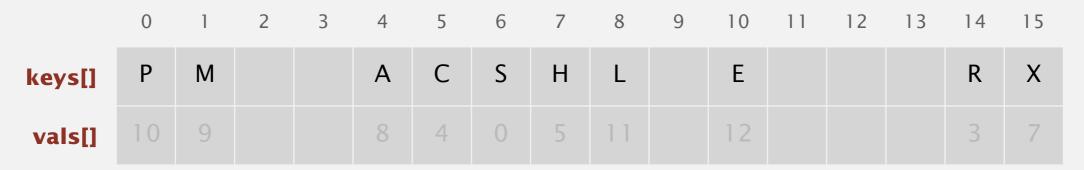
Depois de redimensionar

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
keys[]					Α		S				E				R	
vals[]					2		0				1				3	

Remoção em exploração linear

- P: Como remover uma chave (e seu valor associado)?
- R: Requer algum cuidado: não podemos simplesmente apagar entradas!

Antes de remover S





Remoção em exploração linear

- P: Como remover uma chave (e seu valor associado)?
- R: Requer algum cuidado: não podemos simplesmente apagar entradas! Solução: marcar que o espaço já havia sido ocupado alguma vez

Antes de remover S

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
keys[]	Р	M			Α	С	S	Н	L		Ε				R	X
vals[]	10	9			8	4	0	5	11		12				3	7
used[]	1	1	0	0	1	1	1	1	1	0	1	0	0	0	1	1



Sumário: implementações de dicionário

Implementação		Garantia			Caso médio	Operações ordenadas	Interface	
impiementação	search	insert	delete	search hit	insert	delete	?	principal
Busca sequencial (array aleatório)	N	N	N	½ N	N	½ N		equals()
Busca binária (array ordenado)	lg N	N	N	lg N	½ N	½ N	•	compareTo()
ABP	N	N	N	1.39 lg <i>N</i>	1.39 lg <i>N</i>	\sqrt{N}	•	compareTo()
ABP balanceada (ex: rubro-negra)	2 lg <i>N</i>	2 lg <i>N</i>	2 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	1.0 lg <i>N</i>	✓	compareTo()
Hashing por encadeamento separado	N	N	N	3-5 *	3-5 *	3-5 *		equals() hashCode()
Hashing por exploração linear	N	N	N	3-5 *	3-5 *	3-5 *		equals() hashCode()

^{*} considerando hashing uniforme

Algorithms

ROBERT SEDGEWICK | KEVIN WAYNE

http://algs4.cs.princeton.edu

3.4 TABELAS HASH

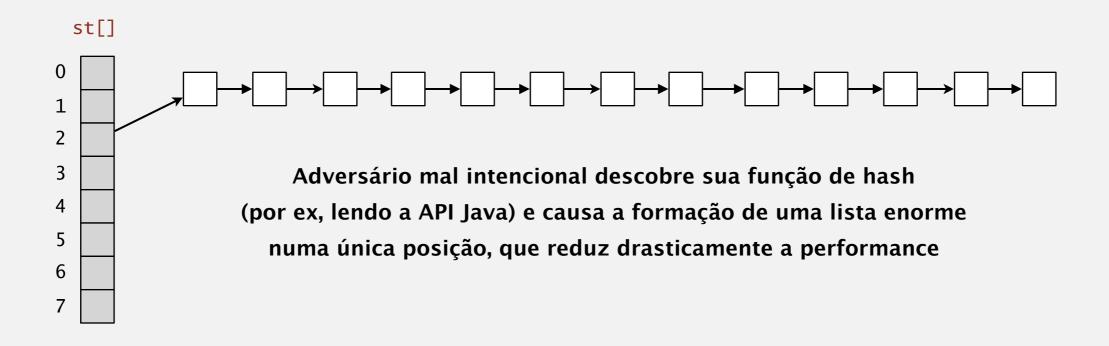
- Funções de hash
- Encadeamento separado
- Exploração linear
- **▶** Contexto

História de guerra: ataques de complexidade algorítmica

P: Por que a ideia de hashing uniforme é importante na prática?

R: Situações óbvias: controle de aeronave, reator nuclear, marca-passo.

R: Situações surpreendentes: ataques de negação de serviço.



Ataques reais: [Crosby-Wallach 2003]

- Servidor Bro: enviar pacotes bem escolhidos para criar negação de serviço, usando menos largura de banda que uma linha discada
- Perl 5.8.0: inserir strings bem escolhidas no array associativo.
- Kernel Linux 2.4.20: gravar arquivos com nomes bem escolhidos.

História de guerra: ataques de complexidade algorítmica

Um relatório de bugs no Java:

Jan Lieskovsky 2011-11-01 10:13:47 EDT

Description

Julian Wälde and Alexander Klink reported that the String.hashCode() hash function is not sufficiently collision resistant. hashCode() value is used in the implementations of HashMap and Hashtable classes:

http://docs.oracle.com/javase/6/docs/api/java/util/HashMap.html http://docs.oracle.com/javase/6/docs/api/java/util/Hashtable.html

A specially-crafted set of keys could trigger hash function collisions, which can degrade performance of HashMap or Hashtable by changing hash table operations complexity from an expected/average O(1) to the worst case O(n). Reporters were able to find colliding strings efficiently using equivalent substrings and meet in the middle techniques.

This problem can be used to start a denial of service attack against Java applications that use untrusted inputs as HashMap or Hashtable keys. An example of such application is web application server (such as tomcat, see buy-4750521) that may fill hash tables with data from HTTP request (such as GET or POST parameters). A remote attack could use that to make JVM use excessive amount of CPU time by sending a POST request with large amount of parameters which hash to the same value.

This problem is similar to the issue that was previously reported for and fixed in e.g. perl:

http://www.cs.rice.edu/~scrosby/hash/CrosbyWallach_UsenixSec2003.pdf

Ataque de complexidade algorítmica no Java

Objetivo: Encontrar família de strings com mesmo *hashCode*.

Solução: O código de *hashCode* que é parte da API de strings.

key	hashCode()
"Aa"	2112
"BB"	2112

key	hashCode()
"AaAaAaAa"	-540425984
"AaAaAaBB"	-540425984
"AaAaBBAa"	-540425984
"AaAaBBBB"	-540425984
"AaBBAaAa"	-540425984
"AaBBAaBB"	-540425984
"AaBBBBAa"	-540425984
"AaBBBBBB"	-540425984

key	hashCode()
"BBAaAaAa"	-540425984
"BBAaAaBB"	-540425984
"BBAaBBAa"	-540425984
"BBAaBBBB"	-540425984
"BBBBAaAa"	-540425984
"BBBBAaBB"	-540425984
"BBBBBBBAa"	-540425984
"BBBBBBBB"	-540425984

2^N strings de tamanho 2N que geram o mesmo hash!

Distração: funções de hash one-way

Função de hash *one-way:* "Difícil" encontrar uma chave que irá gerar um hash para um valor desejado (ou duas chaves que gerem o mesmo hash).

```
Ex. MD4, MD5, SHA-0, SHA-1, SHA-2, WHIRLPOOL, RIPEMD-160, .....

Sabe-se que são inseguras
```

```
String password = args[0];
MessageDigest sha1 = MessageDigest.getInstance("SHA1");
byte[] bytes = sha1.digest(password);

/* Escrever os bytes como string hexadecimal */
```

Aplicações: Assinatura digital, resumos de mensagens, senhas.

Ressalva: Muito custosa para usar em aplicações de dicionário.

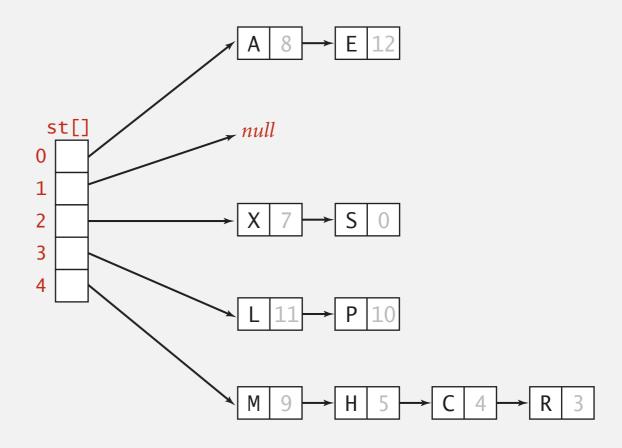
Encadeamento separado x exploração linear

Encadeamento separado:

- · Performance degrada "graciosamente".
- Clustering menos sensível a funções de hash ruins.

Exploração linear:

- Menos espaço perdido.
- Melhor performance de cache.



12 13 14

keys[] vals[]

Р	М		А	С	S	Н	L	E		R	X
10	9		00	4	0	5	11	12		3	7

Tabelas hash x árvores de pesquisa balanceadas

Tabelas hash:

- Código mais simples.
- Não há outra alternativa efetiva para chaves sem critério de ordem.
- Mais rápidas para chaves simples (poucas operações ao invés de $\log N$ comparações).
- Melhor suportadas em Java para strings (faz cache dos hash codes).

Árvores de pesquisa balanceadas:

- Performance garantida.
- Suporte para operações de dicionário ordenado.
- Mais fácil implementar compareTo() do que equals() e hashCode().

Sistema Java inclui ambas:

- ABPs rubro-negras: java.util.TreeMap, java.util.TreeSet.
- Tabelas hash: java.util.HashMap, java.util.IdentityHashMap.